

¿Cómo se siente el presidente?*

Erika Kleiman Tomás Pacheco Abigail Riquelme

30 de junio de 2021

Abstract

Cómo se comunican las personas es un aspecto fundamental en la vida, particularmente en la de un presidente. En este artículo lo que haremos es estudiar la comunicación paraverbal del presidente de Argentina, Alberto Fernández, en Twitter desde su asunción. Para esto utilizamos los textos de sus Tweets y los clasificamos con un algoritmo de análisis de sentimiento, que asigna a cada Tweet la probabilidad de que este tenga un contenido “positivo” o “negativo”. Encontramos que el modelo que mejor pronostica a esta serie es un modelo univariado de suavización exponencial. A su vez, hicimos un estudio de eventos evaluando cómo cambia dicho sentimiento luego de la ocurrencia de ciertos eventos destacables durante la pandemia de COVID-19. Encontramos que luego del anuncio de la cuarentena el 19 de marzo de 2020, el sentimiento positivo del presidente aumentó considerablemente. Estos resultados son estadísticamente significativos.

Palabras clave: Twitter, análisis de sentimiento, Alberto Fernández, pronósticos, estudio de eventos

*Trabajo Final para la materia Pronósticos Financieros de la Universidad de San Andrés, semestre de otoño 2021. Profesora Magdalena Cornejo.

1. Introducción

La comunicación es fundamental en la vida de todas las personas: estudiantes, profesionales, deportistas y políticos, especialmente el presidente. Cuando hablamos de comunicación no solo nos referimos su contenido, sino a la forma en la que se expresan las ideas. Diversos autores han estudiado el paralenguaje que han usado distintos presidentes en actos oficiales o campañas ([McCormick y Stuckey, 2013](#)). Sin embargo, se encuentra poca evidencia de lo que expresan los presidentes a través de Twitter.

En este trabajo lo que haremos es analizar el paralenguaje del actual presidente argentino, Alberto Fernández, desde un enfoque particular: el análisis de sentimiento (*sentiment analysis*, en inglés). Lo que haremos es construir una serie de tiempo utilizando los Tweets que ha publicado desde el inicio de su mandato. A través de este algoritmo se le asignará un valor entre 0 y 1 a cada publicación en la red social, de forma tal de reflejar la probabilidad de que el texto sea “positivo”. Un valor más cercano a 1 representará un sentimiento mayormente positivo, mientras que un valor mas cercano al 0 reflejará un sentimiento negativo. Resulta importante aclarar que a lo largo de todo este trabajo nos referiremos al valor que toma este índice con la palabra *sentimiento*.

El interés de esta investigación es evaluar cómo distintos sucesos durante la pandemia de COVID-19 afectaron en el sentimiento del máximo mandatario. Para hacer esto llevaremos a cabo un estudio de eventos, evaluando la incidencia de distintos acontecimientos, tales como el anuncio de la cuarentena total en marzo de 2019, el proyecto de expropiación de la empresa Vicentín, el fallecimiento de Diego Maradona y la llegada del primer lote de vacunas contra el coronavirus. El segundo interés que tenemos es encontrar la mejor forma de pronosticar cómo serán las emociones del presidente, así cómo cuales son las variables económicas, epidemiológicas y climáticas que determinan el comportamiento. También, analizaremos con cuanta anticipación se pueden hacer predicciones de algo tan subjetivo como lo es el sentimiento de Alberto Fernández.

Dentro de los resultados a los que llegamos podemos destacar que encontramos que el modelo de suavización exponencial (ETS) tiene un muy buen desempeño a la hora de pronosticar, un paso hacia adelante, el sentimiento del presidente. En cuanto a los pronósticos, observamos que resulta muy

difícil predecir correctamente esta variable con una anticipación mayor a día. Por último, concluimos que el anuncio de la cuarentena tuvo un impacto positivo en los primeros siete días en el sentimiento de Alberto Fernández.


El trabajo está dividido en cuatro partes. La primera presenta los datos utilizados. La segunda plantea la metodología y el desarrollo del trabajo. En la tercera parte, haremos referencia a los resultados obtenidos. Finalmente, presentaremos las conclusiones del estudio y sus limitaciones.

2. Datos

2.1. Descripción y fuentes

La principal variable de todo nuestro trabajo, el sentimiento del presidente de la Nación, la construimos a partir de los Tweets que este publicó en la red social desde su asunción el 10 de diciembre de 2019. El contenido de cada Tweet, como también la cantidad de favoritos y de *retweets* fue descargado utilizando la API que la misma red social ofrece. A partir de esta información, construimos nuestra serie aplicándole, a cada Tweet, el análisis de sentimiento. Este análisis, realizado con el paquete SENTIMENT-ANALYSIS-SPANISH en Python, lo que hace es analizar el texto y asignar una probabilidad de que éste refleje un lenguaje positivo. Por ejemplo: el texto “me divierto mucho con mis amigos” va a tener un puntaje alto, dado que refleja un sentimiento positivo, mientras que la frase “me parece terrible esto que me estás haciendo” va a tener asignada una probabilidad que tiende a cero. El algoritmo utiliza redes neuronales para la predicción y, según su [documentación](#), tiene una tasa de acierto del 88 %. Debido a hay días en los que el presidente *twiteó* más de una vez, tomamos el promedio del sentimiento por día. Con el objetivo de ver de manera más clara la tendencia de nuestra serie, lo que hicimos fue aplicarle un suavizado a través de la media móvil tomando cuatro observaciones previas. En la Figura (1) se puede ver nuestra principal serie de interés.

Luego, para poder hacer un estudio de eventos, necesitábamos una variable que refleje, de alguna manera, el sentimiento positivo o negativo que había en Twitter para cada fecha. Para hacer esto, lo que hicimos fue buscar, para cada día, los tres principales *trending topics* en Argentina. Para cada una de estas tendencias, buscamos 51 Tweets que contengan la frase que fue tendencia. Lo siguiente



Fuente: elaboración propia

Figura 1: Sentimiento del presidente Alberto Fernández

fue extraer muestras aleatorias de 31 Tweets para cada combinación tendencia-día. Suponemos que con esta extracción y con 31 observaciones, valiéndonos de la Ley Débil de los Grandes Números¹, tenemos una muestra representativa del sentimiento de Twitter para cada día. A cada uno de los Tweets le aplicamos el análisis de sentimiento y promediamos por día. Por último, aplicamos el mismo suavizado que a la serie del presidente. Más adelante en nuestro trabajo comentaremos las limitaciones de estos datos.

Para realizar los pronósticos utilizamos distintas variables explicativas. Las dos primeras, que surgieron del *scraping* de Tweets fue la cantidad de favoritos y de *retweets* que cada publicación tiene. El resto de las variables podemos dividirlos en tres grupos: variables económicas, variables epidemiológicas y variables climáticas. Dentro del primer grupo tenemos el tipo de cambio contado con liquidación² (pesos por dólares). Estos datos fueron extraídos de [Rava Bursátil](#). La siguiente variable económica que utilizamos fue la tasa de interés mínima de plazo fijo a 30 días, y la serie fue descargada desde el sitio web del Banco Central. De esta misma fuente, utilizamos la serie de

¹Esto es, la media poblacional tiende a la media muestral cuando la cantidad de observaciones tiende a infinito.

²Elegimos el tipo de cambio contado con liquidación dado que Argentina tiene un régimen cambiario de tipo de cambio fijo, entonces, el impacto de la situación macroeconómica no se ve reflejada en el tipo de cambio oficial.

reservas del Banco Central y la base monetaria de Argentina.

El siguiente grupo de variables que utilizamos son las relacionadas a la situación epidemiológica por la pandemia de COVID-19. El año 2020 fue un período en el que toda la discusión pública estuvo centrada en torno a la pandemia. Es por esto que suponemos que puede haber cierta influencia de las series que reflejan la situación epidemiológica en Argentina. Elegimos como predictores la cantidad de casos confirmados de coronavirus y la cantidad de muertos a raíz de esta enfermedad, extraídos de la página del [Ministerio de Salud de la Nación](#). Como la pandemia fue un suceso mundial consideramos relevante incluir en nuestros modelos la situación en Argentina relativa al resto del mundo. Es por esto que construimos una variable que son los casos en Argentina sobre la cantidad de casos diarios en el mundo. Esto nos da un ratio que expresa la proporción de casos en Argentina sobre los mundiales. Lo mismo lo hicimos con las muertes por COVID-19. Los datos de casos y muertes a nivel mundial fueron extraídos de [Our World in Data](#).

Diversos autores ([Howarth y Hoffman, 1984](#); [Keller et al., 2005](#)) relacionan el estado de ánimo de las personas con el clima. Dado que con nuestro análisis intentamos predecir el sentimiento de una persona, consideramos relevante incluir este tipo de variables. Particularmente, utilizamos la temperatura máxima y mínima para cada día en la Ciudad de Buenos Aires. Estos datos fueron extraídos de [World Weather Online](#).

2.2. Características

Para todas las variables antes descritas, tenemos sus valores desde el 11 de diciembre de 2019 hasta el 5 de junio de 2021. Estas series no son continuas debido a que la principal variable (sentimiento del presidente) no tiene valores para todos los días. Esto sucede debido a que el presidente no *twiteó* cada día del período que consideramos. En total, tenemos 483 observaciones en nuestra base de datos. Para hacer el análisis, dividimos los datos en dos ventanas. La primera de ellas, la ventana de estimación (*in-sample*) comienza el 11 de diciembre de 2019 y termina el 28 de noviembre de 2020. Los datos restantes, es decir, desde el 28 de noviembre hasta el 5 de junio de 2021, constituyen nuestra ventana de pronósticos (*out-of-sample*). Esta última representa el 12 % de las observaciones totales.

En la Figura (1) observamos, tal como se especificó anteriormente, nuestra principal variable de interés. En primer lugar, podemos notar que los valores del sentimiento de Alberto Fernández están, durante todo el período analizado, por debajo del 0.5. Es decir, presenta un sentimiento más cercano a cero que a uno, lo cual indica un sentimiento más negativo. En segundo lugar, podemos decir que visualmente se puede identificar una posible tendencia decreciente al inicio del período. Esto parece cambiar levemente entre julio de 2020 y enero de 2021.

Con respecto a las covariables podemos identificar una tendencia creciente en algún momento del período considerado en el tipo de cambio (Figura 20 en Apéndice), la base monetaria (Figura 21 en Apéndice), la cantidad de vacunas aplicadas (Figura 22 en Apéndice), la cantidad de casos de COVID-19 en Argentina relativos respecto del resto del mundo (Figura 23 en Apéndice), la temperatura mínima (Figura 24 en Apéndice), la temperatura máxima (Figura 25 en Apéndice), cantidad de casos de COVID-19 (Figura 26 en Apéndice) y las reservas del BCRA (Figura 27 en Apéndice). En algunas de estas variables es posible observar, a partir de los gráficos, posibles tendencias decrecientes.

También es útil nombrar que, limitándonos al análisis meramente visual, parece que algunas de las covariables presentan estacionalidad, por ejemplo, la temperatura mínima, la temperatura máxima y la cantidad de muertes por COVID-19 en Argentina. Por último, podemos destacar que las variables cantidad de favoritos (Figura 28 en Apéndice) y cantidad de *retweets* (Figura 29 en Apéndice) contienen un valor atípico en, aproximadamente, enero del año 2021.

En general, las conclusiones que se pueden obtener, tanto de la variable de interés como de las covariables, a partir de un análisis visual de los gráficos, no son concretas. Por lo tanto, antes de comenzar a entrenar los modelos para luego pronosticar, le hicimos, a cada una de nuestras series, un test de raíz unitaria para evaluar su estacionariedad. En la Tabla (1) se presenta el test de Dickey Fuller Aumentado seleccionado la longitud de rezago óptima con el criterio de información de Akaike. Esta información es relevante debido a que para la estimación de ciertos modelos como, por ejemplo, el VAR necesitamos que las variables sean estacionarias.

Variable	None	Trend	Drift
SentimientoAF	-4,15***	-9,88***	-9,6***
Favoritos	-11,15***	-14,24***	-13,25***
Retweets	-9,22***	-13,36***	-12,21***
Reservas BCRA	-1.09	1.67	-1.28
L_1 (Reservas BCRA)	-11,73***	-12***	-11,76***
Tasa de interés	-1	-4,11***	-2,86*
Base monetaria	0.3	-5,05***	-3,17**
Tipo de cambio	1.76	-2.57	-1.65
L_1 (Tipo de cambio)	-15,96***	-16,19***	-16,18***
Casos Arg.	-2,91***	-7,38***	-4,38***
Muertes Arg.	-2,82***	-5,39***	-4,46***
Vacunas	-3,75***	-6,58***	-4,4***
Casos Arg. Rel.	-2,17**	-5,05***	-3,89***
Muertes Arg. Rel.	-2,3**	-3,43**	-3,43**
Temp. Min.	-1.45	-4,92***	-4,92***
Temp. Max.	-1.49	-4,9***	-4,91***

Nota: *p<0.1; **p<0.05; ***p<0.01

Cuadro 1: Test de raíz unitaria: Dickey-Fuller aumentado

En la Tabla (1) identificamos que solo hay dos variables que no son estacionarias: el tipo de cambio y las reservas del Banco Central. Comprobamos que la diferencia de estas dos variables sí resulta estacionaria, con lo cual podemos decir que ambas son integradas de grado uno. El resto de las variables consideradas son estacionarias en niveles, es decir, integradas de grado cero. Es útil destacar que los resultados de la estacionariedad de las variables consideradas son robustos a la utilización del test de raíz unitaria de Phillips-Perron (Tabla 9 en Apéndice).

3. Metodología

3.1. Pronósticos

Con el objetivo de realizar pronósticos en el período *out-of-sample* realizamos algunas estimaciones preliminares en la ventana *in-sample*. En particular, comenzamos estimando varios modelos uniecuaciones. Decidimos concentrarnos en los modelos ARIMA, ARIMAX, ETS y ADL. En los modelos ARIMAX y ADL utilizamos las covariables nombradas anteriormente como regresores. También consideramos relevante estimar modelos multiecuaciones como el VAR y el FAVAR.

Antes de estimar los modelos uniecuacionales lo que hicimos fue seleccionar aquellos modelos según algún criterio establecido. En cuanto al modelo ARIMA, podemos decir que elegimos aquel que minimiza el criterio de información de Akaike corregido, este es un ARIMA(5,0,1). Es decir, seleccionamos un modelo autorregresivo de orden 5 con una media móvil. Los resultados de la estimación de este modelo se encuentran en la Columna (1) de la Tabla (2). Es posible observar que el primer, cuarto y quinto componente autorregresivo son estadísticamente significativos.

Con respecto al modelo ARIMAX lo que hicimos fue seleccionar el modelo ARIMA que minimiza el criterio de información de Akaike corregido que, tal como se nombró anteriormente, es un ARIMA (5,0,1). A la estimación de este modelo le incorporamos las covariables como regresores. En la Columna (2) de la Tabla (2) se pueden observar los resultados de esta estimación. Detectamos que nuevamente el primer, cuarto y quinto componente autorregresivo son significativos. Luego, con respecto a la significatividad de las variables incorporadas como regresores solo podemos decir que el tipo de cambio es significativa.

Para estimar el modelo ETS seleccionamos el orden de manera automática con la función `ets` en R. El modelo que resultó fue un ETS(A,Ad,N), esto indica que se incluye un error aditivo y una tendencia aditiva *damped*. Los parámetros de suavización estimados se encuentran en la Columna (3) de la Tabla (2).

También estimamos un modelo ADL, con el objetivo de explicar al sentimiento de Alberto Fernández en función de sus propios rezagos y de los rezagos de las demás variables. El algoritmo seleccionó como mejor modelo al ADL(2, 4, 1, 1, 0, 0, 0, 0, 0, 0, 2, 1, 0, 0). Esto indica que se incluyen dos rezagos para la variable que corresponde al sentimiento del presidente y para la temperatura máxima en Buenos Aires, 1 rezago para la cantidad de *retweets*, las reservas del Banco Central y para la temperatura mínima y 4 rezagos para la cantidad de favoritos. Para el resto de las variables no se incluyen rezagos. Los resultados de la estimación de este modelo se puede observar en la Columna (4) de la Tabla (2). A partir de esta Tabla podemos decir que que las variables relevantes son el primer y segundo rezago del sentimiento de Alberto Fernández, las reservas del BCRA, la tasa de interés, el

Cuadro 2: Estimaciones *in-sample*

	<i>Variable dependiente: SentAF</i>					
	<i>ARIMA</i>	<i>ARIMA</i>	<i>ETS</i>	<i>OLS</i>	<i>VAR</i>	<i>FAVAR</i>
	(1)	(2)	(3)	(4)	(5)	(6)
$L_1(\text{SentAF})$	0,503** (0.201)	0.421** (0.197)		0,800*** (0.054)	0,803*** (0.054)	0,799*** (0.052)
$L_2(\text{SentAF})$	0.151 (0.160)	0.191 (0.163)		-0,174*** (0.049)		
$L_3(\text{SentAF})$	-0.003 (0.060)	-0.024 (0.060)				-0,231*** (0.066)
$L_4(\text{SentAF})$	-0,232*** (0.058)	-0,225*** (0.050)			-0,192*** (0.070)	
$L_5(\text{SentAF})$	0,182*** (0.057)	0,153*** (0.045)			0,252*** (0.067)	0,252*** (0.066)
$L_6(\text{SentAF})$					-0,116** (0.051)	
$MA(1)$	0.296 (0.203)	0,369* (0.190)				
ReservasBCRA				0,0001* (0.00004)		
$L_1(\text{ReservasBCRA})$				-0,0001* (0.00004)		
Tasa de Interés		-0.001 (0.001)		-0,002** (0.001)		
Tipo de Cambio		-0,001** (0.0004)		-0.001 (0.0004)		
$L_1(\text{TwRet})$					-0,00001** (0.00000)	
$L_3(\text{CasosArg})$					0,00001* (0.00001)	
$L_2(\text{MaxTemp})$				-0,002** (0.001)	-0,002* (0.0001)	
$L_1(\text{MinTemp})$				0,002* (0.001)		
$L_1(\text{PC2})$						0.013* (0.007)
$L_6(\text{PC4})$						0.021* (0.012)
Alpha			0.9011			
Beta			0.0001			
Phi			0.822			
Constante	0,154*** (0.009)	0,978*** (0.282)		0.371 (0.281)	0.070 (0.061)	0,141*** (0.033)
Tendencia					-0,0002** (0.0001)	-0,0003*** (0.0001)
Observaciones	425	425	425	421	418	417
R ²				0.573	0.633	0.592
Log Likelihood	614.389	618.204				
Ljung-Box <i>p</i> -valor	0.1405	0.6359	0.0000	0.0026	0.0000	0.00236

Nota:

*p<0.1; **p<0.05; ***p<0.01

primer y segundo rezago de la temperatura máxima y el primer rezago de la temperatura mínima.

Con el objetivo de validar los modelos nombrados anteriormente, aplicamos el test de autocorrelación sobre los residuos de cada uno ellos (Ljung-Box), de esta forma es posible observar si queda o no dinámica en el modelo. La Tabla (2) muestra que con los modelos ARIMA y al ARIMAX estimados no rechazamos la hipótesis de no autocorrelación de los residuos, es decir, que no queda dinámica en los errores. Por lo tanto, podemos validar estos modelos.

Al aplicar el de Ljung-Box a los residuos de los modelos ETS y ADL rechazamos la hipótesis nula de no autocorrelación de los errores. Por lo tanto, no podemos validar estos modelos. Sin embargo, decidimos considerar al ETS y ADL para realizar pronósticos debido a que sabemos que al trabajar con datos diarios es muy difícil incorporar toda la dinámica en el modelo. En otras palabras, con datos diarios es difícil no rechazar la hipótesis nula de no autocorrelación de los residuos.

Luego, estimamos dos modelos multiecuacionales: VAR y FAVAR. Para la estimación del VAR primero seleccionamos el número de rezagos que minimiza el criterio de Final Prediction Error de Akaike. Al realizar esto nos queda un VAR(6). En la Columna (5) de la Tabla (2) se presentan los resultados de la estimación de este modelo en el período *in-sample*. Encontramos que los rezagos que influyen a la hora de explicar el sentimiento de Alberto Fernández, es decir, nuestra variable de interés son el primer, cuarto, quinto y sexto rezago del sentimiento del presidente, el primer rezago de la cantidad de *retweets*, el segundo rezago de la temperatura máxima y el tercer rezago de la cantidad de casos de COVID-19 en Argentina.

Para estimar el modelo FAVAR, lo que hicimos fue aplicar la técnica de componentes principales a nuestras variables explicativas. Luego, seleccionamos la cantidad de componentes que utilizaremos según el valor de los autovalores. Para esta selección hicimos uso del criterio que se presenta en el trabajo de [Stock y Watson \(2012\)](#). Dichos autores plantean que se eligen los componentes principales cuyos autovalores sean mayores a uno. Esto es porque un autovalor mayor que uno implica que ese componente principal explica más varianza que el promedio. Por lo tanto, elegimos los primeros cuatro componentes principales, debido a que tal como se puede ver en la Tabla (3), estos compo-

nentes tienen autovalores mayores a uno.

Componente	Autovalor	Porcentaje de varianza explicada	Porcentaje de varianza explicada acumulada
PC1	5.2991	40.7625	40.7625
PC2	2.9882	22.9859	63.7484
PC3	1.826	14.0463	77.7946
PC4	1.0068	7.7445	85.5391
PC5	0.7692	5.9171	91.4562
PC6	0.551	4.2383	95.6945
PC7	0.2487	1.9128	97.6073
PC8	0.108	0.8306	98.4379
PC9	0.0798	0.6135	99.0515
PC10	0.0475	0.3652	99.4167
PC11	0.0364	0.2801	99.6968
PC12	0.0264	0.2033	99.9001
PC13	0.013	0.0999	100

Cuadro 3: Autovalores de componentes principales

Posteriormente lo que hicimos fue estimar un modelo VAR con el sentimiento de Alberto Fernández y los cuatro componentes principales seleccionados. Para esto aplicamos la función `VARselect` sobre el conjunto de variables nombradas anteriormente. Seleccionamos el número de rezagos que minimiza el criterio de Final Prediction Error de Akaike. De esta forma, nos queda un VAR(8). En la última columna de la Tabla (2) se pueden observar los resultados de la estimación de este modelo. Encontramos que son significativos el primer, cuarto y quinto rezago de la variable del sentimiento de Alberto Fernández. También lo son el primer rezago del segundo componente principal y el sexto rezago del cuarto componente principal.

Nuevamente, con el objetivo de validar los modelos, aplicamos el test de Portmanteau asintótico a los residuos del VAR y FAVAR estimados. Al 1 % no rechazamos la hipótesis de no autocorrelación de los errores para el modelo FAVAR estimado, sin embargo sí rechazamos a todos los niveles comunes de significatividad con el modelo VAR. Si bien no podemos validar mediante el test anteriormente nombrado al modelo VAR decidimos utilizarlo para la realización de pronósticos debido a que, tal como se nombró anteriormente, con datos diarios es difícil no rechazar la hipótesis nula de no autocorrelación de los residuos.

Es útil notar que en la estimación del modelo VAR observamos cierta influencia en la dinámica del sentimiento del presidente de algunos rezagos de determinadas covariables. Por lo tanto, consideramos relevante utilizar diversas técnicas con el objetivo de poder interpretar en un sentido económico el modelo estimado.

En primer lugar, planteamos las funciones de impulso-respuesta (FIR) para observar de qué forma afectan los *shocks* de los predictores a nuestra variable de interés. En las Figuras (2) y (3) presentamos solo las funciones que revelan un efecto de un *shock* de un desvío estándar en una covariable, en el sentimiento del presidente. No incluimos el resto de los gráficos de las funciones de impulso-respuesta debido a que nuestra variable de interés no presenta reacción alguna antes los *shocks* simulados.

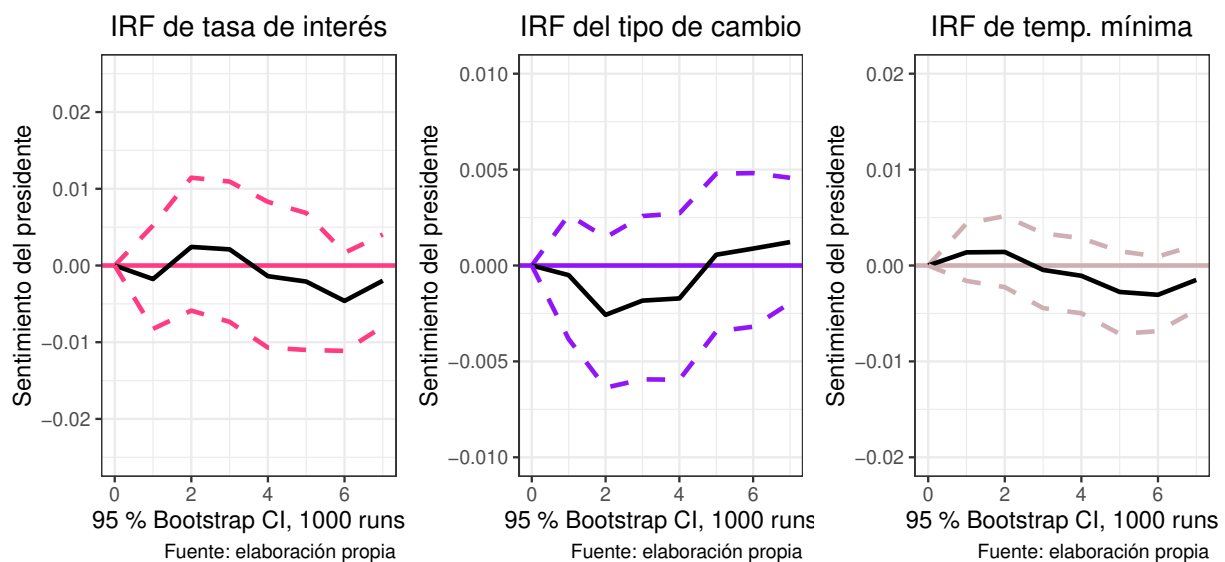


Figura 2: Funciones de impulso-respuesta I

Encontramos que *shocks* en la cantidad de muertes por COVID-19 en Argentina, la cantidad de casos de COVID-19 relativa al resto del mundo, la cantidad de muertes por COVID-19 relativa al resto del mundo, tasa de interés, tipo de cambio y temperatura mínima afectan el sentimiento de Alberto Fernández.

En particular, en la función impulso-respuesta de la tasa de interés (Figura 2) podemos observar que un *shock* en esta variable en cierto momento tiene un efecto negativo en el sentimiento del presidente, con el paso del tiempo este efecto se vuelve positivo (entre el tercer y cuarto día) y luego




Figura 3: Funciones de impulso-respuesta II

vuelve a caer. Estos resultados tienen sentido debido a que podemos pensar que un aumento en la tasa de interés puede reflejar una política del BCRA que tenga como objetivo mantener una rentabilidad positiva de los ahorristas frente a la suba de precios esperada y por lo tanto, contener la migración de depósitos hacia el dólar. De esta forma, el sentimiento positivo del presidente puede ser afectado de manera negativa por este tipo de *shock* debido a que representan un peor escenario económico.

Con respecto a la función impulso-respuesta del tipo de cambio Figura (2) lo que sucede es que, ante un *shock* en esta variable, el sentimiento del presidente cae hasta aproximadamente el cuarto día y luego comienza a subir. Estos resultados parecen razonables debido a que un aumento en el tipo de cambio genera un peor escenario económico para, por ejemplo, los importadores. Por lo tanto, puede suceder que el sentimiento positivo de Alberto Fernández se vea afectado por esta situación.

También, se observa que *shocks* en la temperatura mínima afectan positivamente el sentimiento del presidente. Este efecto comienza a ser negativo, aproximadamente, en el tercer período (Figura 2). Si bien los efectos son pequeños es interesante destacar que estos resultados son consistentes con los encontrados por (Keller et al., 2005), que indican que las personas tienen un mejor estado de ánimo cuando las temperaturas son más cálidas.

Al observar la función de impulso-respuesta de la cantidad de muertes por COVID-19 (Figura 3) podemos identificar que parece tener un leve efecto negativo en el sentimiento de Alberto Fernández. Este se mantiene durante, aproximadamente, los 7 días considerados en el análisis. Esto puede tener

sentido debido a que un aumento en la cantidad de muertes por COVID-19 refleja una peor situación epidemiológica lo cual podría impactar en el sentimiento positivo del presidente.

Luego, si examinamos la función de impulso-respuesta de la cantidad de casos de COVID-19 relativo al resto del mundo (Figura 3), notamos que un *shock* en esta variable afecta negativamente el sentimiento del presidente. Este efecto negativo se mantiene hasta, aproximadamente, el período 2. A partir de ese momento parece aumentar y disminuir de manera leve hasta estabilizarse en los valores iniciales. Nuevamente esto puede ser razonable debido a que un aumento en la cantidad de casos de COVID-19 respecto del resto del mundo refleja una peor situación epidemiológica de Argentina en relación con los demás países, esto podría afectar negativamente el sentimiento del presidente.

Por último, si observamos la cantidad de muertes por COVID-19 relativas al resto del mundo (Figura 3) notamos que un *shock* en esta variable afecta negativamente al sentimiento de Alberto Fernández. A partir del día 4 parece que esta última variable aumenta pero luego vuelve a bajar. Estos resultados tienen sentido debido al mecanismo explicado para el caso de la cantidad de casos de COVID-19 relativos al resto del mundo.

Para completar el análisis del modelo VAR decidimos realizar una descomposición de la varianza. Al utilizar esta técnica es posible observar la proporción de los movimientos de las variables endógenas del sistema que se deben a *shocks* propios o de otras variables. Presentamos el resultado de esta descomposición en la Figura (4).

En la Figura nombrada anteriormente podemos observar que un gran porcentaje de la varianza del sentimiento de Alberto Fernández es explicada por sí misma. Además notamos que esta proporción va decreciendo levemente con el paso del tiempo y que sucede lo contrario con las demás variables consideradas. Aunque debido a que el porcentaje de la varianza del sentimiento del presidente explicado por cada una de estas variables es muy pequeño no es posible distinguir cambios si realizamos un análisis visual del gráfico.




Figura 4:

3.2. Estudio de eventos

En esta sección presentaremos la metodología utilizada para la estimación de los estudios de eventos. Nuestra intención es evaluar si hubo un impacto de ciertos eventos en el sentimiento del presidente Alberto Fernández. Particularmente, evaluaremos cuatro eventos importantes ocurridos durante el año 2020. El 19 de marzo de dicho año, el máximo mandatario hizo una cadena nacional comunicando la firma de un Decreto de Necesidad y Urgencia que declaraba la cuarentena total en todo el territorio argentino ([Clarín, 2020-03-19](#)). Esta fue la primera política relacionada al comienzo de una pandemia que todavía persiste en estos días. Desde nuestro punto de vista, esta fue una política ampliamente aceptada desde diversos sectores. En discursos posteriores siempre se hizo referencia a la “unidad” de todos los argentinos, alegando que estas políticas iban a ser efectivas para mitigar los casos de coronavirus. Es por esto que, para este evento, tenemos la hipótesis de que el presidente presentó un lenguaje más positivo posterior a ese discurso.

El segundo evento que generó un revuelo social importante fue el intento de expropiación de una empresa agrícola, Vicentín. De acuerdo a un artículo publicado en el diario La Nación por [Rosenberg \(2020-11-06\)](#), el 11 de junio el interventor de la empresa ingresó a la sede administrativa, confirman-

do que la empresa se iba a expropiar. Como ya mencionamos, esto generó un revuelo social que desencadenó diversas marchas contrarias a la decisión del gobierno ([Clarín, 2020-07-09](#)). Es por esto que incluimos este evento con el objetivo de ver el efecto, si es que lo hubo, en el sentimiento del presidente a través de Twitter. En tercer lugar, un hecho que conmovió al mundo entero durante el 2020 fue la muerte del futbolista Diego Maradona, el 25 de noviembre de 2020. Al día siguiente, el gobierno organizó su funeral en la Casa Rosada (Casa de Gobierno). En este acontecimiento, se generaron muchas controversias debido a la cantidad de afluencia de gente y la falta de cumplimiento de las medidas sanitarias dispuestas por las autoridades. En esta oportunidad, el presidente también fue muy criticado por la oposición, y es por ello que queremos ver si este evento tuvo algún impacto en la forma mediante la cual se expresa en la red social.

El último evento consiste en ver si un evento esperanzador, como lo fue la llegada del primer lote de vacunas al país, tuvo un efecto positivo en el sentimiento del mandatario. Esto sucedió el 24 de diciembre de 2019, cuando llegó un avión desde Rusia con 300.150 dosis de la vacuna contra el coronavirus ([Benites, 2021-05-29](#)).

Para evaluar el impacto de todos estos eventos en el sentimiento del presidente de la Nación, estimaremos un modelo de mercado. Este modelo proviene de la literatura estadística y lo que hace es relacionar el retorno de un activo con el retorno del mercado en donde dicho activo cotiza ([Campbell, Lo, y MacKinlay, 1997](#)). Para respetar los supuestos clásicos de la estimación por Mínimos Cuadrados Ordinarios, suponemos que los retornos siguen una distribución normal conjunta. La ecuación que estimaremos, dado un activo i es

$$R_{it} = \alpha_i + \beta_i R_{mt} + \varepsilon_{it} \quad (1)$$

como dijimos, suponiendo que $E(\varepsilon_{it}) = 0$ y $var(\varepsilon_{it}) = \sigma_\varepsilon^2$. En esta ecuación, R_{it} y R_{mt} representan los retornos en el momento t del activo i y del mercado m , respectivamente.

En nuestras estimaciones supondremos que los Tweets de Alberto Fernández son un título dentro del mercado de Twitter. Esto es, lo que el presidente refleja es parte de un mercado: Twitter Argentina. Para poder realizar las estimaciones, construimos la serie de tiempo del mercado a utilizar, tal como fue detallado en la [Sección 2](#). Esta variable se puede encontrar graficada en la Figura (5). Con esta

construcción estamos realizando un supuesto relevante: el primero de ellos es que las tres primeras tendencias son representativas del sentimiento de todo Twitter Argentina para cada día.




Figura 5: Sentimiento del presidente y de Twitter Argentina

Luego de presentar las estimaciones de la ecuación (1), presentaremos los resultados sobre qué sucedió con el sentimiento del presidente luego de cada uno de los eventos. A su vez, presentaremos gráficos en los cuales realizamos un análisis de sensibilidad, esto es, evaluar la significatividad estadística de los “retornos anormales” aumentando la cantidad de observaciones post-evento. Finalmente, dado que nos focalizaremos en qué sucede con el sentimiento siete días después del evento y esto representa pocas observaciones, llevaremos a cabo un análisis de potencia.

4. Resultados

4.1. Pronósticos

Para realizar los pronósticos del sentimiento de Alberto Fernández utilizaremos todas las series en niveles, excepto en los casos en los que el modelo requiera una diferenciación de las variables que no son estacionarias (Tipo de cambio y Reservas del BCRA). Los modelos que se utilizarán para

pronosticar son el ARIMA, ARIMAX, ADL, ETS, VAR y FAVAR. Además, realizaremos los pronósticos con esquemas fijos, recursivos y *rolling* y variaremos la cantidad de pasos adelante a partir de los cuales pronosticaremos. En particular, elegimos trabajar con pronósticos uno, dos y siete pasos adelante con el objetivo de evaluar a cuán a largo plazo podemos predecir la variable de interés.

También realizaremos pronósticos con los modelos, esquemas y pasos adelante anteriormente nombrados con la técnica de *bagging* (exceptuando el ADL debido a limitaciones computacionales). El objetivo de esto es ver si es posible mejorar nuestros pronósticos remuestRANDO nuestro período *out-of-sample* utilizando cien muestras *bootstrap* y tomando el promedio³.

En la Figura (6) observamos los pronósticos realizados con los modelos ARIMA, ARIMAX, ETS, ADL, VAR y FAVAR mediante un esquema fijo y un paso hacia adelante. Notamos que el modelo que parece ajustar mejor, tanto con un esquema fijo, recursivo como *rolling* (Figuras ??, ?? que se encuentran en el Apéndice), es el ETS. Siguiendo con este modelo podemos decir que se identifica cierta ventaja de utilizar un esquema *rolling* debido a que, visualmente, los pronósticos conseguidos parecen ajustar mejor. Con respecto a los demás pronósticos no podemos distinguir grandes diferencias solo mediante un análisis de los gráficos, aunque es posible notar ciertas características de, por ejemplo, aquellos que resultan de la aplicación del ADL fijo, recursivo y *rolling* presentan una mayor volatilidad con respecto a la serie original y a los demás pronósticos.

En la Figura (7) observamos los pronósticos realizados con los modelos ARIMA, ARIMAX, ETS, ADL, VAR y FAVAR mediante un esquema fijo y dos pasos hacia adelante. Solo mediante un análisis visual no podemos identificar ventajas en la utilización de un modelo con respecto a los demás para ninguno de los esquemas planteados anteriormente. A pesar de esto podemos notar que, por ejemplo, el modelo ETS pronostica de manera correcta solo que de forma rezagada.

En la Figura (8) se presentan los pronósticos realizados con los modelos ARIMA, ARIMAX, ETS, ADL, VAR y FAVAR mediante un esquema fijo y siete pasos hacia adelante. A partir de un análisis visual no podemos identificar ventajas en la utilización de un modelo con respecto a los demás para

³En el cuerpo de este trabajo presentaremos solo los gráficos más relevantes. El resto de los pronósticos se encuentran graficados en el [Apéndice Online](#).




Figura 6: Pronósticos




Figura 7: Pronósticos

ninguno de los esquemas planteados anteriormente, aunque podemos decir que todos los modelos parecen tener un ajuste no muy bueno.




Figura 8: Pronósticos

En resumen, al analizar los gráficos de los pronósticos podemos decir que surgen claras desventajas al aumentar la cantidad de pasos adelante de los pronósticos. El que los pronósticos con dos pasos hacia adelante empeoren puede dar indicios sobre la importancia de la observación inmediatamente anterior a la que se quiere pronosticar (esto se ve en la Tabla (2) ya que el primer rezago es significativo para todos los modelos). La misma conclusión es posible de extender para el caso de siete pasos hacia adelante.

A continuación presentamos la versión *bagged* de la mayoría de los pronósticos analizados anteriormente. Recordemos que la aplicación de esta técnica se realizó con cien replicaciones. En la Figura (9) podemos observar que aquellos realizados con un esquema fijo, recursivo y *rolling* un paso hacia adelante. Nuevamente parece identificarse una cierta ventaja del modelo ETS sobre los demás pronósticos.




Figura 9: Pronósticos

También, podemos analizar la versión *bagged* de los pronósticos realizados con un esquema fijo, recursivo y *rolling* dos pasos hacia adelante. Tal como sucedía para el caso de la versión tradicional de los pronósticos observamos que al aumentar la cantidad de pasos adelante, los pronósticos empeoran notablemente. Se extienden estas conclusiones para el caso de los pronósticos realizados siete pasos hacia adelante.

Estos resultados nos muestran la importancia de las observaciones cercanas al valor del sentimiento de Alberto Fernández que se quiere pronosticar. Por lo tanto, a priori, parece no haber una ventaja por aumentar la cantidad de pasos adelante de los pronósticos.

Es importante notar que todas las conclusiones anteriores resultaron solo de una inspección visual de los gráficos de pronósticos. A continuación evaluaremos el desempeño de los distintos pronósticos realizados. En particular nos centraremos en tres medidas de desempeño: RMSE, MAE y MAPE. También aplicaremos el test de Diebold Mariano a cada pronóstico utilizando como *benchmark* un AR(1).

Para analizar las medidas de *accuracy* dividiremos los pronósticos según la cantidad de pasos adelante que se utilizan. Es útil notar que las medidas de *accuracy* presentes en las Tablas (4), (10), (11) no son comparables entre sí debido a que tienen diferente cantidad de observaciones, por lo que para poder comparar estas medidas entre todos los modelos deberíamos eliminar las primeras seis observaciones de los pronósticos que son realizados un paso hacia adelante y las primeras cinco observaciones de los pronósticos que son realizados dos pasos hacia adelante. Los resultados de este ajuste se encuentran en las Tablas (12), (13) y (14).

A continuación presentamos, en la Tabla (4), las medidas de *accuracy* de todos los pronósticos realizados un paso hacia adelante junto con los resultados principales del test de Diebold-Mariano. Notemos que al considerar la raíz del error cuadrático medio (RMSE) podemos decir que el modelo que minimiza esta medida es el ETS con esquema *rolling*. Además, los pronósticos conseguidos con el modelo utilizado como *benchmark* tiene un valor de esta medida que es menor al 29 de los 32 pronósticos realizados con los demás modelos. Los únicos pronósticos que presentan una medida menor del RMSE que el *benchmark* son los realizados con los modelos ETS (esquema fijo), ETS (esquema *rolling*) y ETS (esquema recursivo).

Por otro lado, si consideramos el MAE (error medio absoluto), podemos decir que los pronósticos que minimizan esta medida de desempeño son los realizados con el modelo ETS *rolling*. Nuevamente, los pronósticos conseguidos con el modelo AR(1) tiene un valor menor de esta medida que 19 de los 32 modelos considerados. Al igual que para el caso del RMSE los únicos pronósticos que tienen valores del MAE menores que el *benchmark* son los realizados con los modelos ETS (esquema fijo), ETS (esquema *rolling*) y ETS (esquema recursivo). Al tomar en cuenta el MAPE (error medio absoluto porcentual), las conclusiones son idénticas.

En resumen, al observar los valores de las medidas de desempeño de los pronósticos con todos los modelos estimados, podemos destacar algunas conclusiones. En primer lugar, el AR(1) tiene valores menores del RMSE, MAE y MAPE que el 91 % de los pronósticos realizados con los modelos uniecuacionales y multiecuacionales estimados. En segundo lugar, los pronósticos realizados con el

Modelo	RMSE	MAE	MAPE	DM	p-val
AR(1)	0.027	0.0203	12.9416		
ARIMA fijo	0.0334	0.0245	15.4494	2.0719	0.0428
ARIMAX fijo	0.0568	0.0402	25.389	2.8016	0.0069
ETS fijo	0.0061	0.0042	2.6828	-4.5481	0
ADL fijo	0.0536	0.0383	26.1821	2.8608	0.0059
VAR fijo	0.0509	0.0393	28.1487	3.6026	0.0007
FAVAR fijo	0.0319	0.0234	17.4274	1.4153	0.1624
ARIMA rolling	0.0326	0.0232	14.5459	1.8969	0.0629
ARIMAX rolling	0.0523	0.0352	22.0079	2.8093	0.0068
ETS rolling	0.0013	0.0005	0.3129	-4.6385	0
ADL rolling	0.0491	0.0354	24.9638	2.7663	0.0076
VAR rolling	0.0523	0.0402	29.2103	3.6026	0.0007
FAVAR rolling	0.0323	0.0236	16.3943	1.7718	0.0818
ARIMA recursivo	0.0329	0.025	16.5958	1.3993	0.1671
ARIMAX recursivo	0.054	0.0383	24.4712	2.3194	0.024
ETS recursivo	0.0044	0.003	1.92	-4.7159	0
ADL recursivo	0.0503	0.0355	23.6586	2.7663	0.0076
VAR recursivo	0.0509	0.0393	28.1487	3.6026	0.0007
FAVAR recursivo	0.035	0.0248	18.2469	1.7718	0.0012
ARIMA fijo bagged	0.0464	0.0352	22.6713	3.3432	0.0012
ARIMAX fijo bagged	0.0608	0.0462	30.3219	4.4512	0
ETS fijo bagged	0.0314	0.0228	15.5496	1.1765	0.2443
VAR fijo bagged	0.0398	0.0293	17.7966	3.0368	0.0036
FAVAR fijo bagged	0.0414	0.0326	23.5856	3.2481	0.0025
ARIMA recursivo bagged	0.0455	0.0349	23.018	3.8041	0.0003
ARIMAX recursivo bagged	0.0601	0.0464	30.9019	4.8476	0
ETS recursivo bagged	0.0307	0.0224	14.9544	1.013	0.3154
VAR recursivo bagged	0.0408	0.0293	17.3783	3.7137	0.0005
FAVAR recursivo bagged	0.0414	0.0326	23.5856	3.1633	0.0025
ARIMA rolling bagged	0.0454	0.0343	22.0064	3.3432	0.0015
ARIMAX rolling bagged	0.0598	0.0455	29.9137	4.672	0
ETS rolling bagged	0.0302	0.0221	14.7104	0.8857	0.3795
VAR rolling bagged	0.0421	0.0309	17.6673	3.5584	0.0008
FAVAR rolling bagged	0.0403	0.0319	22.6566	3.4552	0.001

Cuadro 4: Medidas de desempeño - Un paso adelante

modelo ETS con esquema fijo, recursivo y *rolling* son los únicos “superadores” al AR(1).

Ahora bien, es útil evaluar si las diferencias de desempeño identificadas anteriormente son estadísticamente significativas, para esto aplicamos el test de Diebold-Mariano. En particular, aplicamos dicho test a los pronósticos realizados un paso hacia adelante con los modelos estimados a lo largo del trabajo contra el AR(1), es decir, contra el *benchmark*. Los resultados se presentan en la Columna (6) de la Tabla (4). Notemos que debido a la forma en la que realizamos este test valores positivos del estadístico reflejan un mejor desempeño del *benchmark* y valores negativos son evidencia de lo contrario.

A partir de los resultados del test de Diebold-Mariano podemos decir que los modelos ARIMA (esquema fijo, *rolling*, recursivo), ARIMAX (recursivo), FAVAR (esquema fijo, *rolling*), ETS *bagged* (esquema fijo, *rolling*, recursivo) no tienen diferencias estadísticamente significativas en su desempeño con respecto al AR(1). Para el resto de los modelos resulta superior el modelo utilizado como *benchmark*, exceptuando el caso de los modelos ETS (esquema fijo, *rolling* y recursivo) donde estos resultan superiores al AR(1).

De la misma manera calculamos las medidas de desempeño de los pronósticos realizados dos y siete pasos adelante con los diferentes modelos estimados, estos resultados están disponibles en las Tablas (10) y (11). Es estos casos se observa que el modelo AR(1) tiene un desempeño estadísticamente superior a la mayoría de los modelos. Tal como se dijo en el análisis gráfico de los pronósticos podemos inferir que esto puede deberse a que, para realizar los pronósticos de nuestra variable de interés, son muy importantes las observaciones anteriores al día que se quiere pronosticar.

Es útil recordar que las medidas de *accuracy* evalúan el desempeño medio a lo largo de todo el período *out-of-sample* pero podría suceder que la *performance* relativa cambie a lo largo del tiempo. Esto se puede testear mediante el Fluctuation Test (Giacomini y Rossi, 2010). Consideramos interesante aplicarle este test a los pronósticos realizados uno, dos y cuatro pasos adelante con los diferentes modelos utilizando, nuevamente, como *benchmark* un AR(1). A continuación se presentan algunos gráficos⁴ que resultan de la aplicación de dicho test sobre los pronósticos realizados con modelos


⁴El resto de los gráficos se encuentran en el [Apéndice Online](#).

fijos uno, dos y siete pasos adelante. Es útil aclarar que, dada la forma en la que realizamos este test, valores positivos del estadístico indican un mejor desempeño de los pronósticos que resultan de la utilización del *benchmark*.

La Figura (10) muestra la aplicación del test de Giacomini-Rossi sobre los pronósticos realizados con esquema fijo y un paso hacia adelante, encontramos que el modelo ETS resulta superador al modelo AR(1) entre las observaciones número 20 y 40 del período *out-of-sample*. También es posible decir que entre el período 35 y 45 el modelo utilizado como *benchmark* resulta estadísticamente superador a los modelos ARIMA, ARIMAX y ADL. Ambos resultados son consistentes con lo encontrado al aplicar el test de Diebold-Mariano. Estas conclusiones son similares al aplicar el test de Giacomini-Rossi a los pronósticos realizados con los modelos que cuentan con esquema recursivo y *rolling*. Es importante destacar que para la realización de este test elegimos un m igual a 5, es decir, este es el tamaño de la ventana *rolling* a partir de la cual se realiza el test de Diebold-Mariano. Por lo tanto, dado que el tamaño de nuestra ventana *out-of-sample* es de 58, el μ que resulta es 0.10, siguiendo lo planteado por [Giacomini y Rossi \(2010\)](#).


La aplicación del test de Giacomini-Rossi sobre estos pronósticos se encuentra en la Figura (11). Notamos que para el caso de este tipo de pronósticos ningún modelo resulta superador al AR(1), es más este modelo resultado superador a la versión *bagged* del ARIMA, ARIMAX, FAVAR y VAR entre las observaciones 35 y 45 del período *out-of-sample*.

La Figura (12) muestra la aplicación del test de Giacomini-Rossi sobre los pronósticos realizados con esquema fijo y dos pasos hacia adelante. A partir de este gráfico podemos concluir que a lo largo de todo el período *out-of-sample* ningún modelo resulta superador al AR(1). En particular, podemos decir que el modelo AR(1) tiene un desempeño mejor y estadísticamente significativo que los modelos ARIMA, ARIMAX, ETS, ADL y FAVAR. Estos resultados son consistentes con lo encontrado al aplicar el test de Diebold-Mariano. También realizamos este tipo de análisis con los esquemas esquema fijos y recursivos dos pasos hacia adelante, así como con la versión *bagged* de cada uno de estos pronósticos (esquema fijo, recursivo y *rolling*), los gráficos se pueden observar en Figuras (33), (34), (35), (36), (37). Las conclusiones que surgen a partir del análisis de estos gráficos



Fuente: elaboración propia


Figura 10: Test de Giacomini Rossi (esquema fijo, un paso adelante)



Fuente: elaboración propia

Figura 11: Test de Giacomini Rossi (esquema fijo *bagged*, un paso adelante)

son similares.



Fuente: elaboración propia

Figura 12: Test de Giacomini Rossi (esquema fijo, dos pasos adelante)

La Figura (13) presenta la aplicación del test de Giacomini-Rossi sobre los pronósticos realizados con esquema fijo y siete pasos hacia adelante. A partir de este gráfico podemos decir que a lo largo de todo el período *out-of-sample* ningún modelo resulta superior al AR(1). Es útil destacar que el modelo AR(1) tiene un desempeño mejor y estadísticamente significativo al desempeño de todos los modelos considerados (ARIMA, ARIMAX, ETS, ADL, VAR y FAVAR). Nuevamente, estos resultados son consistentes con lo encontrado al aplicar el test de Diebold-Mariano. A la vez, realizamos este tipo de análisis con los pronósticos resultantes de la utilización de esquemas fijos y recursivos siete pasos hacia adelante, así como con la versión *bagged* de cada uno de estos pronósticos (esquema fijo, recursivo y *rolling*), los gráficos se pueden observar en Figuras (38), (39), (40), (41), (42). Las conclusiones que surgen a partir del análisis de estos gráficos son similares.

Con el objetivo de evaluar si hay ganancias en realizar la técnica de *bagging* sobre los diferentes modelos estimados decidimos realizar el test de Giacomini-Rossi entre cada pronóstico y su versión *bagged*. Para esto agrupamos los pronósticos en un solo gráfico según el esquema de pronóstico

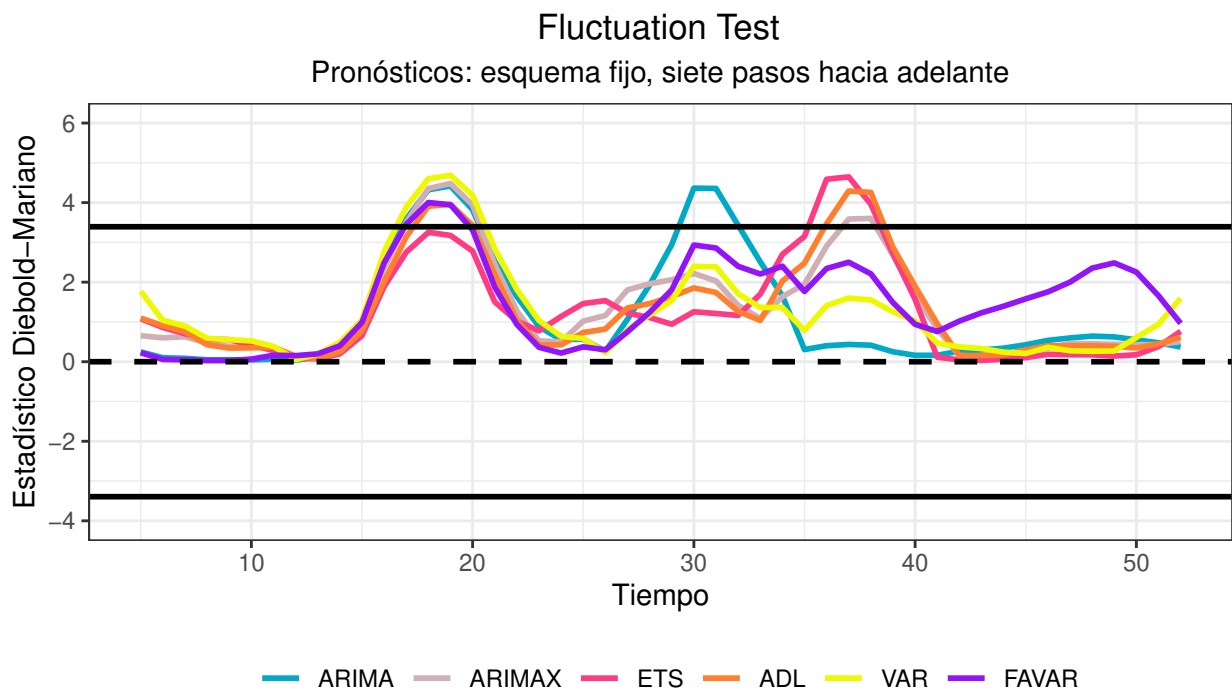



Figura 13: Test de Giacomini Rossi (esquema fijo, siete pasos adelante)

(cantidad de pasos adelante y características de la ventana de estimación). Dada la forma en la que realizamos este test, valores negativos del estadístico reflejan un peor desempeño de la versión *bagged*.

La Figura (14) muestra que la versión *bagged* de los pronósticos realizados con el modelo ETS, ARIMA y FAVAR un paso hacia adelante y con un esquema fijo no resulta superadora a la versión tradicional de cada uno de ellos, esto sucede específicamente entre las observaciones 30 y 40 del período *out-of-sample*. Para el resto de los modelos no encontramos diferencias significativas entre el desempeño de la versión tradicional y el de la versión *bagged*. Estos resultados son similares al aplicar dicho test a los pronósticos con un esquema *rolling* o recursivo (un paso hacia adelante) y su correspondiente versión *bagged*. Los gráficos de estos casos están disponibles en el Apéndice (Figuras 43 y 44).

Ahora bien, cuando consideramos los pronósticos realizados dos pasos adelante, tanto con esquema fijo, *rolling* o recursivo, notamos que, para algunos modelos, la versión tradicional tiene un desempeño estadísticamente peor a la versión *bagged*. A continuación presentamos la Figura (15), esta



Nota: valores negativos reflejan un peor desempeño de la versión bagging.
Fuente: elaboración propia

Figura 14: Test de Giacomini Rossi (esquema fijo, un paso adelante)

corresponde a la aplicación del test de Giacomini-Rossi sobre los pronósticos realizados con un esquema fijo y dos pasos hacia adelante contra su versión *bagged*. Podemos observar que la versión tradicional de los pronósticos realizados con el modelo FAVAR resulta superadora a la versión *bagged*.

En la Figura (16) aplicamos el test de Giacomini-Rossi sobre los pronósticos realizados con esquema fijo siete pasos adelante contra su versión *bagged*. Observamos que en este caso la versión *bagged* de los pronósticos realizados con los modelos ETS y ARIMAX resulta superadora a la versión tradicional. Estos resultados son similares cuando consideramos los pronósticos que resultan de un esquema recursivo o *rolling* (Figuras 45 y 46).

En resumen, podemos decir que hay ganancia de utilizar la técnica de *bagging* para pronosticar cuando realizamos los pronósticos más de un paso adelante y con determinados modelos. En cambio, cuando realizamos los pronósticos un paso adelante no identificamos una ventaja por utilizar *bagging* para pronosticar. Estos resultados no varían en gran manera al utilizar esquemas fijo, recursivos o *rolling*.




Figura 15: Test de Giacomini Rossi (esquema fijo, un paso adelante)




Figura 16: Test de Giacomini Rossi (esquema fijo, un paso adelante)

4.2. Estudio de eventos

Previamente explicamos la metodología a utilizar para estimar el efecto de los eventos sobre el sentimiento promedio. Lo que en un estudio de eventos con verdaderos activos financieros llamaríamos “retorno anormal” en este caso será cuanto aumenta o disminuye el promedio del sentimiento del presidente por sobre lo que aumenta o disminuye el sentimiento general de Twitter Argentina. En este trabajo lo llamaremos por su nombre original: retorno anormal.

Para comenzar nuestro análisis, en la Tabla (5) presentaremos, para cada evento, el promedio del sentimiento del presidente antes y después de cada uno de los acontecimientos.

Evento	Antes	Después
Anuncio cuarentena	-0.0966	0.006
Vicentin	-0.0053	0.0005
Fallecimiento Maradona	-0.0041	0.0032
Primer lote de vacunas	-0.0009	-0.0032

Cuadro 5: Promedio antes y después de cada evento

Para el evento del anuncio de la cuarentena, se puede observar que hay un cambio de signo en el promedio antes y después del evento, denotando que hay un aumento en el positivismo. De la misma forma, para el anuncio de la intervención de Vicentin parecería haber un aumento en el sentimiento. Sin embargo, la magnitud no pareciera ser grande. Luego, para el funeral de Maradona también pareciera haber un aumento, mientras que para la llegada del primer lote de vacunas el efecto parecería ser negativo.

Lo que vimos hasta ahora está lejos de reflejar un impacto causal, dado que la comparación antes-después está sesgada. El paso siguiente será estimar el modelo de mercado, es decir, la ecuación (1). Los resultados se encuentran en la Tabla (6).

Con los retornos anormales ya estimados, nosotros queremos ver qué sucede con estos una semana después del evento. Para probar que dichos retornos siete días después son distintos de cero, utilizamos dos tests estadísticos. El primero de ellos es un test- t , esto es, un test que verifica pa-

<i>Variable dependiente:</i>				
RetSentimientoAF				
	(1)	(2)	(3)	(4)
RetTwitterArg	1.303 (4.259)	0.449 (2.189)	0.272 (1.064)	0.172 (0.972)
Constante	-0.098 (0.677)	-0.008 (0.280)	-0.004 (0.131)	-0.001 (0.122)
Evento	Cuarentena	Vicentin	Maradona	Vacunas
Observaciones	59	142	303	328
R^2	0.002	0.0003	0.0002	0.0001
<i>Note:</i>		*p<0.1; **p<0.05; ***p<0.01		

Cuadro 6: Estimación de modelo de mercado

ramétricamente si las observaciones son distintas de cero. Los p -valores asociados a este test se encuentran en la Columna (1) de la Tabla (7).

Evento	Media	p-val ttest	p-val Wilcoxon
Anuncio cuarentena	0.8838	0.0679	0.0781
Vicentin	0.0421	0.7478	0.6875
Fallecimiento Maradona	0.0017	0.9885	0.9375
Llegada de vacunas	-0.2032	0.2848	0.2969

Cuadro 7: Resultados principales: estudio de evento

Como se puede observar, se rechaza la hipótesis nula de que los valores son iguales a cero solo para el anuncio de la cuarentena. Este resultado es estadísticamente significativo al 10 %. Con esto, estamos comprobando nuestra hipótesis de que el sentimiento del presidente en Twitter se volvió más positivo después del evento. Sin embargo, este test que cuyo estadístico sigue una distribución t -student tiene un problema: asume que las variables se distribuyen normalmente. Dado a que estos retornos no siguen esta distribución (esto se puede verificar en el *script* cuando hacemos los gráficos cuantil-cuantil), para controlar la robustez de estos resultados, hicimos el test no paramétrico del rango, o de Wilcoxon. Esta prueba está especialmente diseñada para muestras chicas y no asume distribución de los datos. Los p -valores de este *test* se encuentran en la columna (2) de la Tabla (7). Los resultados son los mismos que utilizando la prueba paramétrica.

Los resultados mostrados hasta ahora pueden ser producto del azar. Para comprobar que son robustos los resultados a los que llegamos, llevamos a cabo diversos análisis de sensibilidad. Cuando uno

realiza este tipo de estudios siempre puede ocurrir que se confunda el efecto del evento con algún otro acontecimiento que haya sucedido en el pasado. Si esto pasara, el efecto no podría ser atribuido al evento de interés. Para comprobar esto, lo que hicimos fue estimar nuevamente el modelo pero utilizando como *fake treatment* al 12 de marzo de 2019, es decir, una semana antes del evento real y ver qué suceden con los retornos anormales una semana después. Con ninguno de los dos tests logramos rechazar la hipótesis nula. También, para evaluar si el mercado tenía información sobre el anuncio de la cuarentena, repetimos el estudio de eventos para cada uno de los seis días previos anteriores al anuncio del presidente y observamos los retornos anormales siete días después. Los resultados son claros: en la Tabla (8) se puede observar que en ningún momento se rechaza la hipótesis nula de que los retornos son distintos de cero. A modo de chequeo de robustez visual, en la Figura

Fecha de evento	Media ARs	p -val t-test	p -val Wilcoxon
19/03/2019	0.8838	0.0679	0.0781
18/03/2019	0.2875	0.7314	0.375
17/03/2019	0.1272	0.8799	0.6875
16/03/2019	1.0316	0.4123	0.4688
15/03/2019	-0.0154	0.9923	0.9375
14/03/2019	-0.3941	0.8019	0.5781
13/03/2019	1.0794	0.6108	0.8125
12/03/2019	-0.6739	0.7922	0.8125

Cuadro 8: Controles de robustez

(17) se encuentra el gráfico de los retornos anormales luego del evento del 19 de marzo. Se puede ver que luego de esa fecha aumentan y luego se observa que estabilizan entre -1 y 1.

Como mencionamos recientemente, los primeros siete días después del evento se puede ver que son positivos los retornos anormales, y que luego se estabilizan entre dos bandas. Con todo lo mencionado tenemos evidencia estadística para comprobar nuestra hipótesis de que hubo un cambio positivo en el sentimiento del presidente luego de declarar la cuarentena. Comprobamos empíricamente que estos resultados no se deben a sucesos que podrían haber transcurrido días antes.

El segundo análisis de sensibilidad que hicimos fue comprobar si es posible rechazar la hipótesis nula, para alguna cantidad de ventanas hacia adelante, de que los retornos anormales son distintos

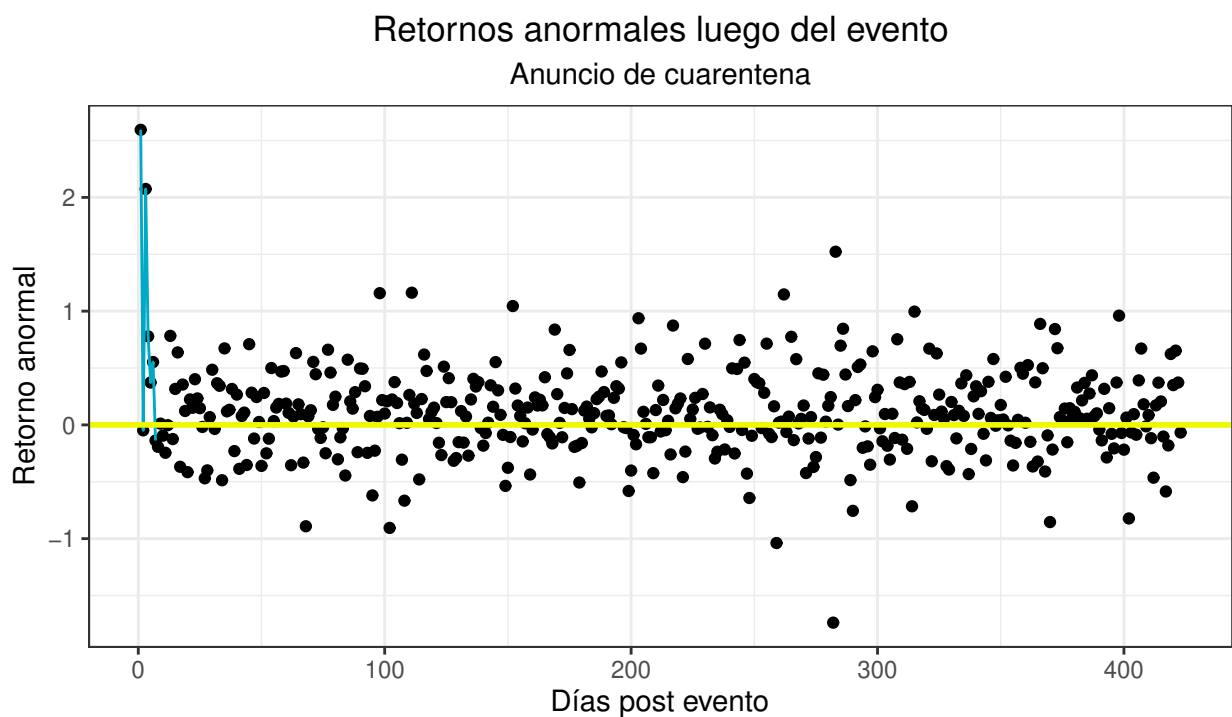



Figura 17: Retornos anormales del sentimiento del presidente

de cero para el evento de llegada de vacunas. En la Figura (18) se pueden ver los resultados.

En el gráfico observamos que solo durante escasos períodos luego de la llegada de vacunas el retorno anormal es distinto de cero, mostrando que podría haber algún efecto. Para el resto de los días no se rechaza la hipótesis nula.

Cuando nosotros estimamos cada uno de los tests, puede suceder que la hipótesis nula no se rechace por dos motivos: el primero de ellos es que el efecto no es lo suficientemente importante como para rechazarla, y el otro motivo está relacionado con la potencia estadística. A su vez, la potencia estadística está vinculada con el tamaño del efecto y con la cantidad de observaciones. Ambos componentes de la potencia se relacionan positivamente, es decir, a mayor cantidad de observaciones mayor será la potencia dado cierto efecto. Entonces, para comprobar que no hayamos rechazado la hipótesis nula por un problema de potencia estadística, haremos un test visual, que se encuentra en la Figura (19).



Fuente: elaboración propia

Figura 18: Análisis de sensibilidad IV




Figura 19: Curvas de potencia estadística

Lo que se puede observar para cada evento son las curvas de potencia hipotéticas, esto es, dado un retorno y cierta cantidad de observaciones se fija cual es la potencia para el test. Para cada uno de los cuatros eventos graficamos una línea vertical del retorno anormal promedio siete días después para ver cual es su potencia. En el primer evento ya sabemos que rechazamos la hipótesis nula, por lo tanto, no lo analizaremos. En cambio, para el resto de los cuatro eventos podemos ver que la potencia es muy baja (principalmente para el funeral de Maradona y la intervención de Vicentin), lo cual nos lleva decir que la ausencia de efecto puede deberse a que realmente no hay efecto o a que tenemos baja potencia.

5. Conclusiones

A lo largo de este trabajo intentamos explicar la evolución del sentimiento en Twitter del presidente Alberto Fernández desde su asunción. Esto lo hicimos con dos enfoques: el primero de ellos consistió en plantear distintos modelos con el objetivo de pronosticar la serie, incluyendo variables económicas, epidemiológicas y climáticas. Para esto utilizamos diversos modelos como lo son el ARIMA, ARIMAX, ETS, ADL, VAR y FAVAR. El segundo enfoque consistió en evaluar si distintos acontecimientos importantes ocurridos durante el año 2020 tuvieron un impacto sobre el sentimiento que expresa en la red social. Esto lo hicimos a través de estudios de eventos.

El primer enfoque que utilizamos para explicar el sentimiento de Alberto Fernández a lo largo del tiempo nos enfrentó con varias decisiones importantes. En primer lugar, tuvimos que definir qué modelos utilizar para luego realizar los pronósticos. Esto trajo consigo otras preguntas sobre la importancia de diversos componentes de la serie de interés, de la inclusión de ciertas variables, entre otras. Ante estos interrogantes decidimos armarnos de un conjunto de modelos muy diversos entre sí. Elegimos modelos uniecuacionales, multiecuacionales, univariados y multivariados.

Posterior a la elección de los modelos y a su estimación tuvimos que decidir las características del esquema de pronóstico, nuevamente, optamos por cubrir todas las posibilidades, elegimos esquemas fijos, recursivos y *rolling* tradicionales y *bagging*. También variamos la cantidad de pasos adelante en los que realizamos cada pronóstico: decidimos realizarlos uno, dos y siete pasos adelante. Esto último tuvo como objetivo evaluar no solo la posibilidad de realizar esto sino también la posible

existencia de alguna ganancia en la realización de pronósticos con una mayor cantidad de pasos adelante.

Al realizar los pronósticos del período *out-of-sample* no solo pudimos identificar modelos y esquemas superadores sino también claras desventajas en la utilización de otros. En particular, pudimos notar que el aumento de la cantidad de pasos adelante según la cual se realizan los pronósticos no trae consigo ningún beneficio, además, resulta evidente la imposibilidad de realizar predicciones con un buen ajuste en estos tipos de esquemas. Limitándonos a los pronósticos realizados un paso hacia adelante podemos decir que hubo un modelo que se destacó tanto visualmente como al evaluar mediante algunos test su desempeño en comparación al *benchmark* elegido, este modelo fue el ETS. Las ventajas de este modelo por sobre los demás se mantuvieron al considerar esquemas fijos, recursivos y *rolling*.

Tal como se nombró anteriormente también decidimos incorporar la técnica de *bagging* para realizar los pronósticos. Notamos que en algunos momentos del período *out-of-sample* estos modelos tienen un desempeño estadísticamente peor, recién aparecen ventajas de la utilización de esta técnica cuando realizamos pronósticos con más pasos adelante.

En resumen, podemos decir que fue de gran utilidad armarnos un conjunto de esquemas de pronósticos variado para de esta forma evaluar cuál de todos ajustaba mejor y por lo tanto reflejaba un mejor desempeño. En nuestro caso, encontramos un modelo superador a los demás y con un ajuste realmente muy bueno al pronosticar un paso adelante el sentimiento de Alberto Fernández. Es útil destacar que al evaluar este modelo en el período *in-sample* llegamos a la conclusión de que había quedado dinámica sin explicar dado que los errores estaban autocorrelacionados. Por lo tanto, remarcamos la importancia de seguir teniendo en cuenta los modelos que tengan estos resultados dada la gran dificultad para los modelos de incorporar toda la dinámica con datos de esta frecuencia.

En cuanto a los estudios de eventos, podemos decir que llegamos a distintas conclusiones. La principal es que luego de declarar la cuarentena el 19 de marzo de 2020, el sentimiento del presidente se volvió más positivo. En este artículo se analiza el efecto una semana después de ocurrido el suceso. Es

válido aclarar que estos resultados son robustos ya que el cambio en los retornos anormales sucede únicamente luego del evento de interés. Al analizar los eventos restantes, como la intervención de Vicentin, el funeral de Diego Maradona y la llegada del primer lote de vacunas al país no pudimos llegar a ninguna conclusión dado que no se rechazan las hipótesis nulas de los tests. Sin embargo, en el trabajo argumentamos que esto se puede deber a un problema de potencia estadística.

Consideramos que los estudios de eventos presentan diversas limitaciones, dado que las conclusiones que presentamos descansan en supuestos que consideramos fuertes. El supuesto más fuerte, o lo que puede presentar mayores limitaciones, es la forma en la que construimos el “mercado” de Twitter Argentina, es decir, utilizando los Tweets relacionados a las tendencias diarias. Como mencionamos en el cuerpo del trabajo, estamos suponiendo que estos 31 Tweets seleccionados aleatoriamente son representativos del sentimiento de Twitter Argentina ese día. Para cualquier estudio de eventos necesariamente hay que suponer que no hubo ningún otro evento que pudiese estar actuando como *confounder*. Aplicado a nuestros eventos, consideramos que de haber encontrado algún efecto para la llegada del primer lote de vacunas deberíamos interpretarlo con cautela, debido a que el 24 de diciembre es la víspera de Navidad y eso puede generar algún sesgo en la estimación.

Como líneas para futura investigación creemos que sería interesante entrenar un modelo de predicción del sentimiento y no utilizar uno que ya esté desarrollado. Por ejemplo, se podría entrenar un modelo de predicción utilizando diversos Tweets que se consideren positivos y otros negativos. Sería relevante ver si las conclusiones cambian tanto a la hora de pronosticar la serie o hacer un estudio de eventos. También creemos que resultaría interesante ampliar la cantidad de tendencias que se usan para construir el sentimiento del mercado, o utilizar Tweets que se hayan publicado a la misma hora que los del presidente.

Referencias

- Benites, C. (2021-05-29). *Argentina superará el lunes los 17,6 millones de vacunas recibidas desde el inicio de la pandemia*. Descargado 2021-06-28, de <https://bit.ly/3dmMDq6>
- Campbell, J., Lo, A., y MacKinlay, C. (1997). The econometrics of financial markets. En (p. 149-179). Princeton University Press.
- Clarín. (2020-03-19). *A través de un dnu: Coronavirus en argentina: Alberto fernández declaró la cuarentena total desde esta medianoche hasta el 31 de marzo*. Descargado 2021-06-28, de <https://bit.ly/3qyyjAi>
- Clarín. (2020-07-09). *La provincia, dividida: Nuevas marchas en contra y a favor de la expropiación de vicentin en santa fe*. Descargado 2021-06-28, de <https://bit.ly/3qAYcj1>
- Giacomini, R., y Rossi, B. (2010). Forecast comparisons in unstable environments. *Journal of Applied Econometrics*, 25(4), 595–620.
- Howarth, E., y Hoffman, M. S. (1984). A multidimensional approach to the relationship between mood and weather. *British Journal of Psychology*, 75(1), 15–23.
- Keller, M. C., Fredrickson, B. L., Ybarra, O., Côté, S., Johnson, K., Mikels, J., ... Wager, T. (2005). A warm heart and a clear head: The contingent effects of weather on mood and cognition. *Psychological science*, 16(9), 724–731.
- McCormick, S., y Stuckey, M. (2013). Presidential disfluency: Literacy, legibility, and vocal political aesthetics in the rhetorical presidency. *Review of Communication*, 13(1), 3–22.
- Rosenberg, J. (2020-11-06). *El gobierno entró a vicentin y concretó la intervención de la empresa*. Descargado 2021-06-28, de <https://bit.ly/35ZHLU0>

Stock, J. H., y Watson, M. W. (2012). Generalized shrinkage methods for forecasting using many predictors. *Journal of Business & Economic Statistics*, 30(4), 481–493.

6. Apéndice



Figura 20: Evolución del tipo de cambio




Figura 21: Base monetaria




Figura 22: Vacunas aplicadas en Argentina




Figura 23: Casos de COVID-19 en Argentina relativos al resto del mundo




Figura 24: Temperatura mínima en Buenos Aires




Figura 25: Temperatura máxima en Buenos Aires




Figura 26: Casos de COVID-19 en Argentina




Figura 27: Evolución de reservas BCRA




Figura 28: Cantidad de favoritos promedios diarios de AF en Twitter




Figura 29: Cantidad de *retweets* promedios diarios de AF





Figura 30: Muertes por COVID-19 en Argentina


Muertes por COVID-19 en Arg. relativas al resto del mundo



Fuente: elaboración propia con datos del Ministerio de Salud y Our World in Data

Figura 31: Muertes por COVID-19 en Argentina relativas al resto del mundo

Evolución de la tasa de interés




Fuente: elaboración propia con datos del BCRA

Figura 32: Evolución de tasa de interés

Variable	Constant	Trend
SentimientoAF	-8,97***	-8,96***
Favoritos	-21,03***	-20,88***
Retweets	-21,48***	-21,26***
Reservas BCRA	-1.13	0.34
L_1 (Reservas BCRA)	-20,73***	-20,58***
Tasa de interés	-2,86*	-3,95**
Base monetaria	-2,86*	-5,07***
Tipo de cambio	-1.47	-2.39
L_1 (Tipo de cambio)	-19,97***	-19,98***
Casos Arg.	-4,34***	-8,93***
Muertes Arg.	-5,48***	-7,65***
Vacunas	-3,56***	-6,32***
Casos Arg. Rel	-5,1***	-7,43***
Muertes Arg. Rel.	-5,32***	-5,62***
Temp. Min.	-7,42***	-7,42***
Temp. Max.	-6,63***	-6,63***

Nota: *p<0.1; **p<0.05; ***p<0.01

Cuadro 9: Test de raíz unitaria: Phillips-Perrón



Fuente: elaboración propia

Figura 33: Test de Giacomini Rossi (esquema fijo *bagged*, dos pasos adelante)

Modelo	RMSE	MAE	MAPE	DM	p-val
AR(1)	0.027	0.0203	12.9416		
ARIMA fijo	0.0671	0.0484	30.3824	3.5074	0.0029
ARIMAX fijo	0.0788	0.0592	40.0506	4.2173	0.0053
ETS fijo	0.0605	0.0417	26.8873	2.3144	0.0054
ADL fijo	0.0795	0.0604	41.8606	4.1535	0.0044
VAR fijo	0.0855	0.0682	46.3931	5.3199	0
FAVAR fijo	0.0653	0.0503	37.5244	4.4518	0.0001
ARIMA rolling	0.0673	0.0475	29.9118	3.7894	0.0009
ARIMAX rolling	0.0761	0.057	39.209	4.2062	0.0031
ETS rolling	0.0599	0.0405	25.867	2.2917	0.0055
ADL rolling	0.0777	0.0576	39.8412	4.191	0.0053
VAR rolling	0.0827	0.0685	47.817	5.3199	0
FAVAR rolling	0.0615	0.0474	34.4186	4.4518	0.0001
ARIMA recursivo	0.0663	0.0502	32.6289	3.1922	0.0023
ARIMAX recursivo	0.0779	0.0585	39.6947	4.0246	0.004
ETS recursivo	0.0604	0.0414	26.6527	2.2177	0.0071
ADL recursivo	0.0757	0.0583	39.7753	4.191	0.0027
VAR recursivo	0.0855	0.0682	46.3931	5.3199	0
FAVAR recursivo	0.0653	0.0503	37.5244	4.4518	0.0001
ARIMA fijo bagged	0.0669	0.0495	31.8679	4.0981	0.0112
ARIMAX fijo bagged	0.0758	0.0578	38.8814	4.9273	0.015
ETS fijo bagged	0.0495	0.037	25.1321	3.0862	0.0053
VAR fijo bagged	0.058	0.0458	34.8237	5.2564	0.0005
FAVAR fijo bagged	0.0612	0.0483	29.7697	4.8801	0.0017
ARIMA recursivo bagged	0.0659	0.0516	33.8482	4.7263	0.0044
ARIMAX recursivo bagged	0.0757	0.0587	39.8667	5.0854	0.0082
ETS recursivo bagged	0.0483	0.0361	24.1977	3.0042	0.0074
VAR recursivo bagged	0.0577	0.0461	34.9536	5.5331	0.0003
FAVAR recursivo bagged	0.0612	0.0483	29.7697	5.1281	0.0007
ARIMA rolling bagged	0.0648	0.0479	31.0202	4.0981	0.0067
ARIMAX rolling bagged	0.0754	0.0577	38.9541	4.9836	0.0115
ETS rollingbagged	0.0465	0.0346	23.199	2.8069	0.0105
VAR rolling bagged	0.0568	0.0461	34.1419	5.5392	0.0002
FAVAR rolling bagged	0.0624	0.048	28.0772	4.7957	0.0042

Cuadro 10: Medidas de desempeño - Dos pasos adelante

Modelo	RMSE	MAE	MAPE	DM	p-val
AR(1)	0.027	0.0203	12.9416		
ARIMA fijo	0.0979	0.0718	41.9783	3.8376	0.1046
ARIMAX fijo	0.1085	0.0841	53.3781	5.3229	0.0332
ETS fijo	0.1258	0.0988	62.6587	5.0666	0.0234
ADL fijo	0.1203	0.0955	62.1464	5.3216	0.0088
VAR fijo	0.1178	0.0945	57.0427	5.6956	0.0053
FAVAR fijo	0.0974	0.0774	56.4159	5.736	0.0045
ARIMA rolling	0.1014	0.0757	45.3812	5.0562	0.0182
ARIMAX rolling	0.1122	0.0865	55.0441	5.342	0.0269
ETS rolling	0.1269	0.0992	62.7152	5.0475	0.0222
ADL rolling	0.1169	0.0911	58.7146	5.1146	0.0183
VAR rolling	0.1153	0.0897	51.7223	5.6956	0.0053
FAVAR rolling	0.0995	0.0785	58.1676	5.736	0.0045
ARIMA recursivo	0.103	0.0803	51.2706	4.2899	0.0589
ARIMAX recursivo	0.112	0.0876	56.638	5.0864	0.0247
ETS recursivo	0.1263	0.099	62.7496	5.0182	0.0202
ADL recursivo	0.1156	0.0899	57.2586	5.1146	0.0147
VAR recursivo	0.1178	0.0945	57.0427	5.6956	0.0059
FAVAR recursivo	0.0974	0.0774	56.4159	5.736	0.0045
ARIMA fijo bagged	0.0977	0.0714	41.6699	4.3179	0.0724
ARIMAX fijo bagged	0.1015	0.0806	50.8023	5.3367	0.0367
ETS fijo bagged	0.1152	0.0918	57.3427	5.5014	0.0272
VAR fijo bagged	0.0988	0.0809	58.8527	5.5027	0.0274
FAVAR fijo bagged	0.1107	0.0872	51.98	6.0884	0.0068
ARIMA recursivo bagged	0.1029	0.08	51.0016	5.055	0.0172
ARIMAX recursivo bagged	0.1042	0.0841	54.1666	5.58	0.0268
ETS recursivo bagged	0.1153	0.0919	57.3593	5.4871	0.0266
VAR recursivo bagged	0.0991	0.0812	59.0755	5.3808	0.0266
FAVAR recursivo bagged	0.1107	0.0872	51.98	6.1134	0.0033
ARIMA rolling bagged	0.1011	0.0752	45.0955	4.3179	0.0475
ARIMAX rolling bagged	0.1022	0.0816	51.3057	5.3461	0.0327
ETS rolling bagged	0.1155	0.0921	57.3954	5.4809	0.0263
VAR rolling bagged	0.0992	0.0818	59.5085	5.2592	0.0255
FAVAR rolling bagged	0.1119	0.0872	51.4602	6.1572	0.0064

Cuadro 11: Medidas de desempeño - Siete pasos adelante

Modelo	RMSE	MAE	MAPE
AR(1)	0.0272	0.0199	11.7229
ARIMA fijo	0.0339	0.0245	14.475
ARIMAX fijo	0.0561	0.0384	21.9768
ETS fijo	0.0059	0.004	2.3262
ADL fijo	0.0526	0.0364	21.9033
VAR fijo	0.0519	0.0403	26.9462
FAVAR fijo	0.0326	0.0238	17.7084
ARIMA rolling	0.0335	0.0236	13.9279
ARIMAX rolling	0.0515	0.0332	18.8498
ETS rolling	0.0003	0.0002	0.119
ADL rolling	0.0469	0.0331	19.9401
VAR rolling	0.0536	0.0418	28.5978
FAVAR rolling	0.0333	0.0243	17.0737
ARIMA recursivo	0.0333	0.0251	15.7337
ARIMAX recursivo	0.0528	0.0363	20.9487
ETS recursivo	0.0041	0.0028	1.568
ADL recursivo	0.0492	0.0335	19.2795
VAR recursivo	0.0519	0.0403	26.9462
FAVAR recursivo	0.0362	0.0257	19.1493
ARIMA fijo bagged	0.0462	0.0339	20.0392
ARIMAX fijo bagged	0.0599	0.0448	26.1011
ETS fijo bagged	0.0308	0.0217	13.372
VAR fijo bagged	0.0407	0.0297	15.9783
FAVAR fijo bagged	0.0419	0.0323	22.4242
ARIMA recursivo bagged	0.0454	0.0339	20.8127
ARIMAX recursivo bagged	0.0594	0.0452	26.9945
ETS recursivo bagged	0.0306	0.0217	13.2934
VAR recursivo bagged	0.0421	0.0302	16.2416
FAVAR recursivo bagged	0.0419	0.0323	22.4242
ARIMA rolling bagged	0.0455	0.0334	19.8575
ARIMAX rolling bagged	0.0592	0.0443	25.9910
ETS rolling bagged	0.0302	0.0214	13.1529
VAR rolling bagged	0.0437	0.0323	17.0944
FAVAR rolling bagged	0.0406	0.0315	21.2807

Cuadro 12: Medidas de desempeño comparables - Un paso adelante

Modelo	RMSE	MAE	MAPE
AR(1)	0.0272	0.0199	11.7229
ARIMA fijo	0.068	0.0484	27.6155
ARIMAX fijo	0.0764	0.0568	33.7166
ETS fijo	0.0601	0.0403	23.5391
ADL fijo	0.0766	0.0566	34.4656
VAR fijo	0.0861	0.0679	43.6133
FAVAR fijo	0.0667	0.0511	36.393
ARIMA rolling	0.0677	0.047	26.6962
ARIMAX rolling	0.0738	0.0545	33.2014
ETS rolling	0.0596	0.0392	22.8974
ADL rolling	0.0743	0.0536	31.8055
VAR rolling	0.0838	0.0692	46.2827
FAVAR rolling	0.0627	0.0479	32.9934
ARIMA recursivo	0.0671	0.0503	30.0189
ARIMAX recursivo	0.0754	0.056	33.3446
ETS recursivo	0.0601	0.04	23.3171
ADL recursivo	0.0729	0.0548	32.6322
VAR recursivo	0.0861	0.0679	43.6133
FAVAR recursivo	0.0667	0.0511	36.393
ARIMA fijo bagged	0.0671	0.0487	28.2236
ARIMAX fijo bagged	0.0745	0.0563	33.1239
ETS fijo bagged	0.0484	0.0357	21.3069
VAR fijo bagged	0.0585	0.0462	32.8637
FAVAR fijo bagged	0.062	0.0486	27.0081
ARIMA recursivo bagged	0.0662	0.0512	30.6702
ARIMAX recursivo bagged	0.0745	0.0572	34.27
ETS recursivo bagged	0.0476	0.0351	20.7833
VAR recursivo bagged	0.0583	0.0465	33.0954
FAVAR recursivo bagged	0.062	0.0486	27.0081
ARIMA rolling bagged	0.0649	0.047	27.4579
ARIMAX rolling bagged	0.0742	0.0561	33.3089
ETS rollingbagged	0.0459	0.0336	19.9576
VAR rolling bagged	0.0573	0.0464	32.166
FAVAR rolling bagged	0.0639	0.0491	26.2551

Cuadro 13: Medidas de desempeño comparables - Dos pasos adelante

Modelo	RMSE	MAE	MAPE
AR(1)	0.0272	0.0199	11.7229
ARIMA fijo	0.0979	0.0718	41.9783
ARIMAX fijo	0.1085	0.0841	53.3781
ETS fijo	0.1258	0.0988	62.6587
ADL fijo	0.1203	0.0955	62.1464
VAR fijo	0.1178	0.0945	57.0427
FAVAR fijo	0.0974	0.0774	56.4159
ARIMA rolling	0.1014	0.0757	45.3812
ARIMAX rolling	0.1122	0.0865	55.0441
ETS rolling	0.1269	0.0992	62.7152
ADL rolling	0.1169	0.0911	58.7146
VAR rolling	0.1153	0.0897	51.7223
FAVAR rolling	0.0995	0.0785	58.1676
ARIMA recursivo	0.103	0.0803	51.2706
ARIMAX recursivo	0.112	0.0876	56.638
ETS recursivo	0.1263	0.099	62.7496
ADL recursivo	0.1156	0.0899	57.2586
VAR recursivo	0.1178	0.0945	57.0427
FAVAR recursivo	0.0974	0.0774	56.4159
ARIMA fijo bagged	0.0977	0.0714	41.6699
ARIMAX fijo bagged	0.1015	0.0806	50.8023
ETS fijo bagged	0.1152	0.0918	57.3427
VAR fijo bagged	0.0988	0.0809	58.8527
FAVAR fijo bagged	0.1107	0.0872	51.98
ARIMA recursivo bagged	0.1029	0.08	51.0016
ARIMAX recursivo bagged	0.1042	0.0841	54.1666
ETS recursivo bagged	0.1153	0.0919	57.3593
VAR recursivo bagged	0.0991	0.0812	59.0755
FAVAR recursivo bagged	0.1107	0.0872	51.98
ARIMA rolling bagged	0.1011	0.0752	45.0955
ARIMAX rolling bagged	0.1022	0.0816	51.3057
ETS rollingbagged	0.1155	0.0921	57.3954
VAR rolling bagged	0.0992	0.0818	59.5085
FAVAR rolling bagged	0.1119	0.0872	51.4602

Cuadro 14: Medidas de desempeño comparables - Siete pasos adelante




Figura 34: Test de Giacomini Rossi (esquema recursivo *bagged*, dos pasos adelante)




Figura 35: Test de Giacomini Rossi (esquema *bagged rolling*, dos pasos adelante)




Figura 36: Test de Giacomini Rossi (esquema recursivo, dos pasos adelante)






Figura 37: Test de Giacomini Rossi (esquema *rolling*, dos pasos adelante)




Fuente: elaboración propia

Figura 38: Test de Giacomini Rossi (esquema fijo *bagged*, siete pasos adelante)




Fuente: elaboración propia

Figura 39: Test de Giacomini Rossi (esquema recursivo *bagged*, siete pasos adelante)




Fuente: elaboración propia

Figura 40: Test de Giacomini Rossi (esquema *bagged rolling*, siete pasos adelante)




Fuente: elaboración propia

Figura 41: Test de Giacomini Rossi (esquema recursivo, siete pasos adelante)



Fuente: elaboración propia

Figura 42: Test de Giacomini Rossi (esquema *rolling*, siete pasos adelante)



Nota: valores negativos reflejan un peor desempeño de la versión bagging.
Fuente: elaboración propia

Figura 43: Test de Giacomini Rossi (comparación con modelos *bagged*: *rolling* un paso adelante)




Figura 44: Test de Giacomini Rossi (comparación con modelos *bagged*: esquema recursivo un paso adelante)





Figura 45: Test de Giacomini Rossi (comparación con modelos *bagged*: esquema recursivo siete pasos adelante)



Nota: valores negativos reflejan un peor desempeño de la versión bagging.
Fuente: elaboración propia

Figura 46: Test de Giacomini Rossi (comparación con modelos *bagged*: esquema *rolling* siete pasos adelante)